


Veri Tipleri




istdatascience.com | info@istdsa.com



tr.linkedin.com/school/istanbul-data-science-academy



medium.com/istanbuldatascienceacademy



REGRESYON PROBLEMİ

Diyelim ki, elimizde evlere ait özellikler var ve bu özellikleri kullanarak evin fiyatını tahmin etmek istiyoruz. Elimdeki bu veriyi nasıl yapılandırmam gerekiyor?

FİYAT	METREKARE	ODA SAYISI	RENK	GARAJ
\$400.000	141	2	Siyah	Paylaşımlı
\$600.000	182	3	Mavi	Kişiyeye Özel
\$350.000	125	2	Beyaz	Yok
\$500.000	157	3	Mavi	Kişiyeye Özel



REGRESYON PROBLEMİ

Diyelim ki, elimizde evlere ait özellikler var ve bu özellikleri kullanarak evin fiyatını tahmin etmek istiyoruz. Elimdeki bu veriyi nasıl yapılandırmam gerekiyor?

FİYAT	METREKARE	ODA SAYISI	RENK	GARAJ
\$400.000	141	2	Siyah	Paylaşımlı
\$600.000	182	3	Mavi	Kişiyeye Özel
\$350.000	125	2	Beyaz	Yok
\$500.000	157	3	Mavi	Kişiyeye Özel

- Bu özellikleri doğrudan lineer regresyon modelimde kullanabilir miyim?

REGRESYON PROBLEMİ

Diyelim ki, elimizde evlere ait özellikler var ve bu özellikleri kullanarak evin fiyatını tahmin etmek istiyoruz. Elimdeki bu veriyi nasıl yapılandırmam gerekiyor?



FİYAT	METREKARE	ODA SAYISI	RENK	GARAJ
\$400.000	141	2	Siyah	Paylaşımlı
\$600.000	182	3	Mavi	Kişiye Özel
\$350.000	125	2	Beyaz	Yok
\$500.000	157	3	Mavi	Kişiye Özel

- Sayısal sütunları **EVET**, ancak kategorik sütunlar için durum bu kadar basit değil.

KATEGORİK SÜTUNLARLA DERDİMİZ NE?

- Dünya üzerindeki tüm bilgisayarların yapı taşları, bir diğer deyişle "hücreleri" 0 ve 1 rakamlarından ibarettir. Bu durumda bilgisayarlar, kullanıcının kendilerine iletmek istediği şeyi tamamen kendi dillerinde yani; 0'ler ve 1'lar şeklinde algılıyor.
- Örneğin, siz "selam" yazmak için klavyenizde gerekli harflere bastığınızda; bilgisayar bunları "harf" olarak değil, her harfin karşılığına denk gelen, **0 ve 1'lerden oluşan bir sayı bütünü** olarak algılıyor.
- Tam olarak bu sebepten ötürü, biz veri bilimciler makine öğrenmesi modelleri geliştirmek istediğimizde elimizdeki **kategorik verileri bilgisayarın anlayabilmesi için sayısal verilere dönüştürmemiz** gerekiyor. Peki nasıl?

DUMMY VARIABLE (ONE-HOT ENCODING)

Bu dönüşümü yapmanın birden çok yolu var. Ancak hangi dönüşümü uygulayacağımızı belirlemek için elimizdeki veriyi iyi tanımamız gerekiyor.



RENK	SİYAH	MAVİ	BEYAZ
Siyah	1	0	0
Mavi	0	1	0
Beyaz	0	0	1
Mavi	0	1	0

- `pd.get_dummies(sütun_adı)`

DUMMY VARIABLE (ONE-HOT ENCODING)

Peki, gerçekten 3 sütunu da dönüştürmeye ihtiyacımız var mı? İşte buna "**Dummy Variable Trap**" diyoruz. Neden mi? Çünkü veri setimizdeki **multicollinearity** sorunu oluşturuyor!



RENK	SİYAH	MAVİ
Siyah	1	0
Mavi	0	1
Beyaz	0	0
Mavi	0	1

- `pd.get_dummies(sütun_adı, drop_first=True)`

DUMMY VARIABLE (ONE-HOT ENCODING)

Ek olarak Dummy Variable yönteminin bir kullanılma çeşidi daha var. Eğer veri setinizde çok sayıda NaN değer varsa, bu duruma ilişkin bir sütun oluşturmak da mümkün.



EVİN SATIŞ FİYATI	NaN
\$540.000	0
NaN	1
\$280.000	0
NaN	1

- `pd.get_dummies(sütun_adı, dummy_na=True)`

LABEL ENCODING

Dummy Variable yönteminin mantığını öğrendik. Peki, aynı yaklaşım tarzını evin garaj durumunu dönüştürme de kullanabilir miyiz?



GARAJ	PAYLAŞIMLI	KİŞİYE ÖZEL
Paylaşımlı	1	0
Kişiyeye Özel	0	1
Yok	0	0
Paylaşımlı	1	0

LABEL ENCODING

Cevap aslında evet ama Dummy Variable yöntemi eğer değişkenlerimiz arasında bir ilişki varsa bunu kaybetmemize sebep olur. Yani farklı bir yaklaşım tarzına ihtiyacımız var.



GARAJ	GARAJ
Paylaşımlı	0.5
Kişiyeye Özel	1
Yok	0
Paylaşımlı	0.5

- Makine öğrenmesi modelleri geliştirirken içeriğinde sayısal değerler barındıran sütunları doğrudan kullanabilirken, içeriği kategorik değerlerden oluşan sütunları modellerimize doğrudan girdi olarak veremeyiz. **Onları dönüştürmemiz lazım!**
- Ancak bu dönüştürme işlemi elimizdeki kategorik verinin tipine göre de değişkenlik gösterir. **Eğer bu değerler arasında ilişki varsa, onları kaybetmemek gerekir!**
- Encoding yöntemleri sadece **Dummy Variable** ve **Label Encoding**'le sınırlı değildir. Bunlar şu aşamada bizim için yeterli. Ancak daha fazla yöntem için;
 - <https://ai-ml-analytics.com/encoding/>