


Sınıflandırma Problemlerine Giriş



istdatascience.com | info@istdsa.com




tr.linkedin.com/school/istanbul-data-science-academy



medium.com/istanbuldatascienceacademy

SUPERVISED VS UNSUPERVISED LEARNING


Makine öğrenmesi temel olarak 2'ye ayrılır. Bunlar **supervised** ve **unsupervised** learning problemleridir.



SUPERVISED LEARNING
(Tahmin edilecek alan biliniyor)

UNSUPERVISED LEARNING
(Tahmin edilecek alan bilinmiyor)

MODELİ DEĞERLENDİRME



REGRESYON VS SINIFLANDIRMA




Regression



What will be the temperature tomorrow?

84°



Fahrenheit

Classification



Will it be hot or cold tomorrow?

COLD

HOT




Fahrenheit

SINIFLANDIRMA PROBLEMLERİ

1 FEATURE: Hastada saptanan hastalıklı hücre sayısı


2 LABEL: Hastanın durumu (**Lost** / **Survived**)



SINIFLANDIRMA PROBLEMLERİ

2 FEATURE: Hastada saptanan hastalıklı hücre sayısı + Hastanın yaşı


2 LABEL: Hastanın durumu (**Lost** / **Survived**)



SINIFLANDIRMA PROBLEMLERİ

2 FEATURE: Hastada saptanan hastalıklı hücre sayısı + Hastanın yaşı

2 LABEL: Hastanın durumu (**Lost** / **Survived**)



K-NEAREST NEIGHBORS (KNN) ALGORİTMASI

BANA ARKADAŞINI SÖYLE, SANA KİM OLDUĞUNU SÖYLEYİYİM

Mevlana Celaleddin Rumi




KNN algoritması oldukça temel bir stratejiye dayanır ve bu sebeple mantığını öğrenmesi de en basit olan algoritmalarından bir tanesidir.

- Komşu sayısını belirleyin (**k** parametresi)
- Uzunluk metriğini belirleyin (çoğunlukla **Euclidean** kullanılır)
- Belirlenen parametrelere göre bulunan en yakın komşulara bakın
- Elde edilen sonuca göre **yeni gözlemin hangi sınıfta olacağına** karar verin


HADI PROBLEMİZE GERİ DÖNELİM

O zaman, hadi en yakın komşularımızın sınıflarına bakalım...




HADI PROBLEMİZE GERİ DÖNELİM

O zaman, hadi en yakın komşularımızın sınıflarına bakalım...




HADI PROBLEMİZE GERİ DÖNELİM

O zaman, hadi en yakın komşularımızın sınıflarına bakalım...




HADI PROBLEMİZE GERİ DÖNELİM

O zaman, hadi en yakın komşularımızın sınıflarına bakalım...




HADI PROBLEMİZE GERİ DÖNELİM

O zaman, hadi en yakın komşularımızın sınıflarına bakalım...




HADI PROBLEMİZE GERİ DÖNELİM

O zaman, hadi en yakın komşularımızın sınıflarına bakalım...




HADI PROBLEMİZE GERİ DÖNELİM

O zaman, hadi en yakın komşularımızın sınıflarına bakalım...



HADI PROBLEMİZE GERİ DÖNELİM


O zaman, hadi en yakın komşularımızın sınıflarına bakalım...



- Regresyon problemlerinde amacımız elimizdeki veri noktalarına en yakın regresyon çizgisini oluşturmaktır. Sınıflandırma problemlerinde ise durum biraz daha farklı, modelin elimizdeki verinin hangi sınıfta olacağına karar vermesi gerekiyor.
- Bunu yaparken de, kullandığımız algoritma ona verilen girdileri kullanarak, tahminleri yapabilmesi için decision regionlar oluşturur.
- Decision regionları oluşturduktan sonra ise, modelin tahmin yapmasını istediğimiz bir girdi geldiğinde bu girdinin hangi sınıfa ait olması gerektiğini oluşturduğu bu alanlara göre karar verir.


DECISION REGION SINIRLARI

O zaman hadi sadece 1 komşuya baktığımızda sınırlarımız nasıl oluşuyormuş onu inceleyelim.



DECISION REGION SINIRLARI

Peki 5 komşuya bakarsak?




DECISION REGION SINIRLARI

Ya 34 komşu?

K = 34

Yaş




Kanserli Hücre Sayısı

● Lost

● Survived


MULTICLASS - DECISION REGION SINIRLARI

Ancak tabiki elimizde sadece 2 adet sınıf olması gerekmiyor. Daha fazlası da olabilir.



LEZZETLİ BİR MEYVE SUYU HAZIRLAMA

- Hadi sıcak havalarda bizi serinletmesi için soğuk, karışık bir meyve suyu hazırlamak istediğimizi varsayalım. Eğer ortaya homojen ve güzel bir karışım çıkarmak istiyorsak kullanacağımız meyve miktarlarına dikkat etmeliyiz.
- Örneğin; **muz**, **elma**, **çilek** ve **blueberry** meyvelerin karışımından oluşan bir meyve suyu yapmak isteyelim. Peki, eğer biz bu karışımın içerisine her meyveden 1 tane koyarsak nasıl bir sonuçla karşılaşırız?
- Böyle bir durumda, muhtemelen muz ve elma tadını aldığımız bir meyve suyu içeceğiz.
- Ama biz karışımın içerisine çilek ve blueberry de koymuştuk onlara ne oldu?



ÖNEMLİ BİR ÖNİŞLEME ADIMI - SCALING


- Evet, çünkü bu meyvelerin **boyutları birbirinden farklı**. Doğru homojen karışımı elde edebilmemiz için bu durumu göz önünde bulundurmamız gerekiyor.
- Bu durum makine öğrenmesi problemlerinde de çok benzerdir. Biz insan olarak **10 gr** ile **10\$**, tamamen iki farklı şey olduğunu biliriz. Ancak makineler bunu anlamaz ve her ikisini de aynı şekilde ele alırlar. Benzer şekilde, 10 gram yerine **0.01 kilogramı** makinelere girdi olarak verirsek bu sefer de 10\$ özelliğimiz daha dominant olacaktır.
- Dolayısıyla **veri noktaları arasındaki mesafeyi kullanan makine öğrenmesi yöntemlerinde**, birimler arasındaki bu soruna bir çözüm üretebilmemiz elimizdeki özellikleri ölçeklendirmemiz lazım!

PEKİ NE ZAMAN SCALING KULLANICAZ?


Algorithms	Feature Scaling
Linear/Non-Linear Regressions	Yes
Logistic Regression	Yes
KNN	Yes
SVM	Yes
Neural Networks	Yes
K-means clustering	Yes
CART	No
Random Forests	No
Gradient Boosted Decision Trees	No
Naïve Bayes	No
PCA	Yes
SVD	Yes
Factorization Machines	Yes

Fig: Feature Scaling requires based on Machine Learning


LİNEER REGRESYON VS LOGISTIC REGRESYON



İşte Logistic Regresyon'da tahminleri gerçekleştirmek için kullanılan bu çizgiye **Sigmoid Fonksiyonu** adını veririz. Ve normal regresyon problemlerinde amacımız bir sayısal değer tahmini yapmakken, burada durumun **0 mı?/1 mi?** olarak gerçekleşeceğini tahmin etmektir.



LOGISTIC REGRESYON




LOGISTIC REGRESYON



Bu özelliklere sahip olan biri muhtemelen obezdir. Ancak %100 obezdir diyebilir miyiz?


KİŞİSEL ÖZELLİK

LOGISTIC REGRESYON



KİŞİSEL ÖZELLİK

LOGISTIC REGRESYON



Bu özelliklere sahip olan biri de muhtemelen obez değildir. Ancak **%100** obez değildir diyebilir miyiz?

KİŞİSEL ÖZELLİK

LOGISTIC REGRESYON



KİŞİSEL ÖZELLİK

LOGISTIC REGRESYON



Peki şimdi? Sanırım noktamız hangisine daha yakınsa onu tahmin olarak kullanacağız.

KİŞİSEL ÖZELLİK

THRESHOLD DEĞERİ

Yani günün sonunda elimizdeki veri hangi sınıfımıza daha yakınsa o şekilde sınıflandıracağız. İşte bu hangi sınıfa ait olduğunu belirlemek için sınıflar arasında ayırım yaptığımız değere **threshold değeri** denir ve threshold bize hangi durumlarda, hangi sınıfın tahmin edileceği bilgisini verir.

