

Clustering Problemlerine Giriş



istdatascience.com | info@istdsa.com




tr.linkedin.com/school/istanbul-data-science-academy



medium.com/istanbuldatascienceacademy

SUPERVISED VS UNSUPERVISED LEARNING

Makine öğrenmesi temel olarak 2'ye ayrılır. Bunlar **supervised** ve **unsupervised** learning problemleridir.



SUPERVISED LEARNING
(REGRESSION & CLASSIFICATION)
(Tahmin edilecek alan biliniyor)

UNSUPERVISED LEARNING
(CLUSTERING)
(Tahmin edilecek alan bilinmiyor)



SINIFLANDIRMA VS CLUSTERING



Classification


vs

Clustering



SINIFLANDIRMA PROBLEMLERİ

Örneğin, elimizdeki veri seti içerisindeki bilgileri kullanarak doğacak olan bir bebeğin cinsiyetini tahmin etmeye çalışalım. Burada tahminlerimizi nasıl yapacağımız oldukça net.



CLUSTERING PROBLEMLERİ


Bu örneğimizde ise, elimizdeki veri seti içerisindeki bilgileri kullanarak kişilerin hangi yaş grubuna gireceğini tahmin etmeye çalışalım. Burada ise durum biraz daha karışık...

- Yaşları kaç gruba ayıracağım?

- Çocuk / Yetişkin?


- Çocuk / Yetişkin / Yaşlı?

- Bebek / Çocuk / Genç / Yetişkin / Yaşlı?




- Daha da fazlasına mı ihtiyacım var? Optimum bir değeri var mı? Benim amacım ne?

BİRDEN FAZLA ÖZELLİKLE CLUSTERING




- Peki benim bir fikrim olmadığı durumlarda optimum cluster sayısını nasıl belirleyeceğim?

BİRDEN FAZLA ÖZELLİKLE CLUSTERING



- Verilerimiz içerisindeki paternleri bularak :)
- Peki paternleri nasıl bulacağım?

BİRDEN FAZLA ÖZELLİKLE CLUSTERING




- K-Means algoritmasının bana sunduğu çıktılarından yararlanarak :)

K-MEANS ALGORİTMASI


KNN algoritmasını hatırlıyor musunuz? İşte K-Means onun unsupervised learning problemlerinde kullanılmak üzere geliştirilmiş olan hali :)

- Örneğin aşağıdaki verilerimi 2 clustera ayırmak istiyorum. Olaylar nasıl gerçekleşiyor?




K-MEANS ALGORİTMASI

- İlk aşamada tamamen rastgele 2 tane cluster merkezi tanımlıyoruz.




K-MEANS ALGORİTMASI

- Belirlenen merkezlere göre veri noktaları hangisine daha yakınlarsa o clustera atanıyor.




K-MEANS ALGORİTMASI

- Sonrasında ise atanan clusterların orta noktası yeni merkez noktamız oluyor.




K-MEANS ALGORİTMASI

- Ve clusterlar merkez noktasına göre tekrardan atanıyor...




K-MEANS ALGORİTMASI

- Ve tekrardan yeni merkez noktalarının belirlenmesi...




K-MEANS ALGORİTMASI

- Ve clusterlar merkez noktasına göre tekrardan atanıyor...




K-MEANS ALGORİTMASI

- Peki bu işlem nereye kadar devam edicek?




K-MEANS ALGORİTMASI

- Merkez deęişiminin ardından clusterlarımız aynı kalana kadar :)




K-MEANS ALGORİTMASI

- Peki elimdeki bu veriyi 3 clustera bölmek istesem?




K-MEANS ALGORİTMASI

- İlk rastgele merkez seçiminin nasıl yapıldığına göre karşımıza farklı sonuçlar gelecektir.



K-MEANS ALGORİTMASI

- Böyle bir durumda hangi seçeneğin daha iyi olduğuna karar vermemiz gerekiyor.



Bu çıkarımı yapabilmek için hangi seçeneğimizde kümelerin birbirlerine en yakın olarak seçildiğine bakabiliriz. Ve en dengeli olan dağılımı şampiyon olasılığımız olarak seçeriz.

- İşte bu mesafelerin kareleri toplamında elde ettiğimiz değere **inertia** adına veriyoruz ve düşük inertia değerleri bizim için **daha kararlı clusterlar** anlamına gelir.


$$I = \sum_{j=1}^k \sum_{x_i \in \text{cluster } j} |x_i - x_{c,j}|^2$$

Diagram illustrating the Inertia formula with annotations:

- sum over clusters**: Points to the outer summation index j .
- sum over points in cluster j** : Points to the inner summation index $x_i \in \text{cluster } j$.
- position of point i in cluster j** : Points to the variable x_i .
- position of centroid of cluster j** : Points to the variable $x_{c,j}$.


K-MEANS ALGORİTMASI

Inertia: 12.645




K-MEANS ALGORİTMASI

Inertia: 12.943




K-MEANS ALGORİTMASI

Inertia: 13.112




K-MEANS ALGORİTMASI

Inertia: 12.645



K-Means'i kullanarak verilerimizi birbiriyle nasıl kümeleyebileceğimizi gördük. Ama hala cevaplamamız gereken önemli bir sorumuz var. **Verilerimi kaç clustera ayırmalıyım?**




- Proje konunuza zaten hakimseniz, **o alandaki bilgi birikiminizi kullanarak** uygun bir karar verebilirsiniz. Ama ya hakim değilsek?
- Burada tekrardan K-Means'in bize sunduğu çıktılardan yararlanmamız gerekiyor.
- Peki nasıl?

OPTIMUM CLUSTER SAYISI PROBLEMİ


Elimizdeki cluster sayısını ne kadar arttırırsak, clusterlar içerisindeki veri noktaları arasındaki fark giderek azalır bu da daha düşük inertia değerleri elde etmemizi sağlar.

- Ancak ne kadar çok cluster o kadar iyi midir? **Tabiki HAYIR!**



OPTİMUM CLUSTER SAYISINI BELİRLEME

Cluster sayımızı en iyi şekilde belirlemek için inertia değerinin **ciddi anlamda düştüğü son cluster değeri** bizim için en optimum değer olur. Ve bu değere **dirsek değeri** deriz.



OPTIMUM CLUSTER SAYISINI BELİRLEME

Peki bu örnekte hangi cluster sayısı bizim için en iyi seçenek olarak duruyor?

