


# Topic Modeling



[istdatascience.com](http://istdatascience.com) | [info@istdsa.com](mailto:info@istdsa.com)




[tr.linkedin.com/school/istanbul-data-science-academy](https://tr.linkedin.com/school/istanbul-data-science-academy)



[medium.com/istanbuldatascienceacademy](https://medium.com/istanbuldatascienceacademy)

# TOPIC MODELING

Metin verileri içerisinde yer alan kelimeler incelenerek **bu kelimelerin oluşturduğu dokümanların gruplanması** yaklaşımına **topic modeling** adını veriyoruz.



# METİN VERİLERİYLE ÇALIŞMAK

Ancak bu noktada karşımıza çıkan bir sorun var. Önceden de konuştuğumuz gibi bizim metin verileri içerisindeki **tüm kelimelere ihtiyacımız yok**.

Bu konuda uygulayabileceğimiz bazı ön işleme adımlarını zaten önceki derslerimizde konuştuk. Ama şimdi bu olayı biraz daha detaylandıralım.

# ELİMİZDEKİ ŞU 5 CÜMLEYE BAKALIM

- I like bananas and oranges.
- Frogs and fish live in ponds.
- Kittens and puppies are fluffy.
- For breakfast, I had a spinach and apple smoothie.
- My kitten loves kale.

Bu cümlelerden 2 tane konu oluşturmak istesek nasıl bir ayırım yapardık?

# ELİMİZDEKİ ŞU 5 CÜMLEYE BAKALIM

- I like **bananas** and **oranges**. %100 TOPIC A
- **Frogs** and **fish** live in ponds. %100 TOPIC B
- **Kittens** and **puppies** are fluffy. %100 TOPIC B
- For **breakfast**, I had a **spinach** and **apple smoothie**. %100 TOPIC A
- My **rabbit** loves **carrots**. %50 TOPIC A / %50 TOPIC B

Peki bulduğumuz bu Topic A ve Topic B ne?



# ELİMİZDEKİ ŞU 5 CÜMLEYE BAKALIM

- I like **bananas** and **oranges**. **%100 FOOD**
- **Frogs** and **fish** live in ponds. **%100 ANIMAL**
- **Kittens** and **puppies** are fluffy. **%100 ANIMAL**
- For **breakfast**, I had a **spinach** and **apple smoothie**. **%100 FOOD**
- My **rabbit** loves **carrots**. **%50 FOOD / %50 ANIMAL**

# WORDS (3D) --> TOPICS (2D)

- I love my pet rabbit.
- That dish yesterday was amazing.
- She cooked the best rabbit dish ever.
- I gave the leftovers of that dish to my pet, Mr. rabbit!
- Rabbits make messy pets.
- My rabbit growls when I pet her.
- He has five rabbits.
- I had this weird dish with fried rabbits.
- That's my pet rabbit's favorite dish.

Şimdi de gelin buradaki cümlelerden topicleri çıkarmaya çalışalım.



# WORDS (3D) --> TOPICS (2D)

- I love my **pet rabbit**.
- That **dish** yesterday was amazing.
- She cooked the best **rabbit dish** ever.
- I gave the leftovers of that **dish** to my **pet**, Mr. **rabbit**!
- **Rabbits** make messy **pets**.
- My **rabbit** growls when I **pet** her.
- He has five **rabbits**.
- I had this weird **dish** with fried **rabbits**.
- That's my **pet rabbit**'s favorite **dish**.

Elimizde 3 tane feature var:

**Rabbit**

**Pet**

**Dish**

- Stop wordsleri(tek başına anlam ifade etmeyen) kaldıralım
- Sadece **isim(noun)** olan kelimeleri kullanalım ve **kelime köklerini** elde edelim



# WORDS (3D) --> TOPICS (2D)

- I love my **pet rabbit**.
- That **dish** yesterday was amazing.
- She cooked the best **rabbit dish** ever.
- I gave the leftovers of that **dish** to my **pet**, Mr. **rabbit**!
- **Rabbits** make messy **pets**.
- My **rabbit** growls when I **pet** her.
- He has five **rabbits**.
- I had this weird **dish** with fried **rabbits**.
- That's my **pet rabbit**'s favorite **dish**.

Elimizde 3 tane feature var:

**Rabbit**

**Pet**

**Dish**

Ama ben bu cümlelerden 2 tane **topic** elde etmek istiyorum?

# HANGİ 2 TOPIC?

Bu seçimi yapmanın temel olarak 2 yolu var.


- **Feature Selection**

- Hangi kelimenin daha az önemli olduğuna karar vermem gerekiyor
- Herbir kelimenin geçme sıklığını kullanabilirim

- **Feature Extraction**


- Bu 3 kelimenin kombinasyonundan oluşacak 2 yeni feature oluşturabilirim
- Principal Component 1
- Principal Component 2

# WORDS (3D) --> TOPICS (2D)




# WORDS (3D) --> TOPICS (2D)

I love my **pet** **rabbit**.



# BUNDAN SONRASI CLUSTERING PROBLEMİ :)

I love my **pet rabbit**.





# CLUSTERLARIMIZA TEKRAR BAKALIM

- I love my pet rabbit.
- Rabbits make messy pets.
- My rabbit growls when I pet her.
- He has five rabbits.
- That dish yesterday was amazing.
- She cooked the best rabbit dish ever.
- I had this weird dish with fried rabbits.
- I gave the leftovers of that dish to my pet, Mr. rabbit!
- That's my pet rabbit's favorite dish.

Şimdi elimizdeki 3 clusterı, 2 cluster'a düşürmeye çalışalım.



# CLUSTERLARIMIZA TEKRAR BAKALIM

- I love my pet rabbit.
- Rabbits make messy pets.
- My rabbit growls when I pet her.
- He has five rabbits.
- That dish yesterday was amazing.
- She cooked the best rabbit dish ever.
- I had this weird dish with fried rabbits.
- I gave the leftovers of that dish to my pet, Mr. rabbit!
- That's my pet rabbit's favorite dish.

**Eksen 1:**  $1.5(\text{Rabbit}) + 1.1 (\text{Pet}) + 0.1(\text{Dish})$

**Eksen 2:**  $0.9(\text{Rabbit}) + 0.02(\text{Pet}) + 1.6(\text{Dish})$



# EKSENLERE GÖRE TEKRARDAN BAKALIM

- I love my **pet rabbit**.
- **Rabbits** make messy **pets**.
- My **rabbit** growls when I **pet** her.
- He has five **rabbits**.

**Eksen 1:** Güçlü

**Eksen 2:** Zayıf

- That **dish** yesterday was amazing.
- She cooked the best **rabbit dish** ever.
- I had this weird **dish** with fried **rabbits**.

**Eksen 1:** Zayıf

**Eksen 2:** Güçlü

- I gave the leftovers of that **dish** to my **pet**, Mr. **rabbit**!
- That's my **pet rabbit**'s favorite **dish**.

**Eksen 1:** Güçlü

**Eksen 2:** Güçlü

**Eksen 1:**  $1.5(\text{Rabbit}) + 1.1(\text{Pet}) + 0.1(\text{Dish})$

**Eksen 2:**  $0.9(\text{Rabbit}) + 0.02(\text{Pet}) + 1.6(\text{Dish})$

# CLUSTER ---> TOPIC

- I love my **pet rabbit**.
- **Rabbits** make messy **pets**.
- My **rabbit** growls when I **pet** her.
- He has five **rabbits**.
- That **dish** yesterday was amazing.
- She cooked the best **rabbit dish** ever.
- I had this weird **dish** with fried **rabbits**.
- I gave the leftovers of that **dish** to my **pet**, Mr. **rabbit**!
- That's my **pet rabbit's** favorite **dish**.

Topic 1: 1.5(**Rabbit**) + 1.1 (**Pet**) + 0.1(**Dish**) ---> Pet, Pet Rabbit

Topic 2: 0.9(**Rabbit**) + 0.02(**Pet**) + 1.6(**Dish**) ---> Food, Rabbit Dishes

# CLUSTER ---> TOPIC

|                                                                                   | TOPIC 1 | TOPIC 2 |
|-----------------------------------------------------------------------------------|---------|---------|
| • I love my <b>pet rabbit</b> .                                                   | %87     | %13     |
| • <b>Rabbits</b> make messy <b>pets</b> .                                         | %88     | %12     |
| • My <b>rabbit</b> growls when I <b>pet</b> her.                                  | %80     | %20     |
| • He has five <b>rabbits</b> .                                                    | %66     | %34     |
| • That <b>dish</b> yesterday was amazing.                                         | %2      | %98     |
| • She cooked the best <b>rabbit dish</b> ever.                                    | %16     | %84     |
| • I had this weird <b>dish</b> with fried <b>rabbits</b> .                        | %15     | %85     |
| • I gave the leftovers of that <b>dish</b> to my <b>pet</b> , Mr. <b>rabbit</b> ! | %47     | %53     |
| • That's my <b>pet rabbit</b> 's favorite <b>dish</b> .                           | %42     | %58     |

Artık başta istediğimiz 2 tane topici oluşturmuş olduk. Ancak bunların hangi konuları barındırdığını belirlemek de size kalmış :)

- Topic modeling, elimizdeki dokümanların içerisindeki bilgilerden yararlanarak, bu **dokümanlarda hangi konuların geçtiğini** tespit edebildiğimiz bir NLP yaklaşımıdır.
- Konularımızı belirlerken dikkat etmemiz gereken 2 konsepti anlamaya çalıştık:
  - Topiclerin nasıl oluşturulduğunu
  - Çok boyutlu verilerden nasıl daha az boyutlu verilere geçebildiğimizi (Dimensionality Reduction)

# DIMENSIONALITY REDUCTION

Evet, **Dimensionality Reduction** yönteminden yararlanarak elimizdeki çok boyutlu bilgileri nasıl daha küçültebileceğimizi topic modeling konusu içerisinde gördük.

Ancak, Dimensionality Reduction bizim başka birçok problemimizi çözebilen çok değerli bir yaklaşım tarzı! Dolayısıyla bunun hakkında biraz daha detaylı konuşmamız gerekiyor.

Şimdi gelin bu konuyu biraz daha detaylandıralım...

